

Mineração de Dados de Queimadas no Brasil

Pipeline de Engenharia e Mineração de Dados para Análise de Focos de Incêndio — 2023 a 2025

ENGENHARIA DE DADOS · MACHINE LEARNING · INPE



Contexto e Problema

O Desafio Ambiental

O Brasil registrou crescimento expressivo nos focos de incêndio, com impactos severos sobre biodiversidade, saúde pública e emissões de carbono.

O Problema Analítico

Mais de 12 milhões de registros ambientais dificultam a identificação manual de padrões espaciais e climáticos. Técnicas de mineração de dados são essenciais para extrair conhecimento acionável.

Fontes de Dados

Dados públicos do **INPE** (Instituto Nacional de Pesquisas Espaciais) acessados via plataforma **Base dos Dados**, integrados ao Google BigQuery.

Objetivos do Projeto

Objetivo Geral

Analisar os focos de queimadas no Brasil entre 2023 e 2025 por meio de um pipeline completo de engenharia e mineração de dados, gerando insights analíticos e geoespaciais acionáveis.

Objetivos Específicos

- Identificar **clusters geográficos** de epicentros de incêndio por ano
- Detectar **padrões climáticos** associados a biomas e estados
- Gerar **visualizações analíticas** e mapas interativos
- Aplicar os algoritmos **K-Means** e **Apriori** em escala real

Base de Dados



Origem e Volume

Microdados públicos do **INPE** disponibilizados via **Base dos Dados** no Google BigQuery, cobrindo o período de 2023 a 2025.

Principais Variáveis


- Coordenadas geográficas (latitude, longitude)
- Bioma, estado e município
- Precipitação, risco de fogo e dias sem chuva
- Data e intensidade do foco

+12 milhões
de registros processados


27 estados
e 6 biomas brasileiros

3 anos
de série histórica (2023–2025)

Arquitetura do Pipeline



O pipeline integra ingestão distribuída no BigQuery com cache local em **Apache Parquet**, reduzindo o tempo de carregamento de minutos para poucos segundos após a primeira execução. As etapas de clusterização e mineração são orquestradas via `main.ipynb` em Jupyter.



Tecnologias Utilizadas



Infraestrutura

Google BigQuery para consultas distribuídas; **Apache Parquet** para cache local otimizado; **basedosdados** para acesso programático.



ML & Mineração

scikit-learn (K-Means) para clusterização geoespacial; **apyori** (Apriori) para mineração de regras de associação climática.



Visualização

folium para mapas interativos em HTML; **matplotlib** e **seaborn** para gráficos estatísticos com escala logarítmica.



Linguagem & Dados

Python como linguagem central; **pandas** e **pyarrow** para manipulação e engenharia de dados em larga escala.

Metodologia – Clusterização Espacial



Algoritmo K-Means


O algoritmo segmenta amostras estratificadas por estado em **N_CLUSTERS = 7**, identificando automaticamente os epicentros de incêndio por ano.

- Cada foco é colorido conforme seu cluster
- Epicentros marcados com ícones de fogo
- Mapas exportados como .html interativos
- Análise de densidade geográfica por bioma



A estratificação por estado garante representatividade regional e evita viés de concentração nos estados com maior volume de registros.

Metodologia – Clusterização Espacial



- Usamos a regra do cotovelo para definir de forma mais objetiva o número ideal de clusters, evitando escolhas arbitrárias. Esse método analisa a variação interna dos grupos conforme aumentamos o número de clusters e identifica o ponto em que adicionar mais grupos deixa de trazer melhorias significativas.
- A partir dessa análise, o resultado indicou **2 clusters** como o ponto ideal, o que mostrou uma separação natural dos dados. Isso acabou dividindo o Brasil em duas regiões com comportamentos distintos em relação às queimadas.
- Em vez de impor uma segmentação pré-definida, utilizamos o próprio padrão dos dados para revelar essa estrutura. Assim, a análise baseada na regra do cotovelo reforça que a divisão em dois grupos não foi artificial, mas sim uma consequência do comportamento observado nos dados de queimadas no país.

Metodologia — Regras de Associação (Apriori)

Pré-processamento Climático

Variáveis numéricas são categorizadas automaticamente para alimentar o algoritmo Apriori:

categoria_chuva	categoria_seca	categoria_risco	categoria_potencia	estacao
chuva_baixa	seca_alta	risco_alto	potencia_media	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_alta	primavera

Métricas de Avaliação

Suporte

Frequência do itemset no corpus total

Confiança

Probabilidade condicional da regra

Lift

Fator de correlação entre antecedente e consequente

Potencia fogo

Potencia Alta / Média / Baixa

Risco de Fogo

Risco Alto / Medio / baixo

Dias sem Chuva

Chuva Baixa / Media /Alta

Resultados — Padrões Descobertos

Regras de Associação com Maior Correlação


- 1

SE: chuva baixa + estação primavera + seca alta
ENTÃO: risco de fogo alto
(confiança: 99,8%)

Interpretação:
Quando há pouca chuva combinada com longos períodos de seca durante a primavera, o ambiente fica muito mais seco e propício à ignição de incêndios. Esse padrão mostra uma forte relação entre condições climáticas extremas e aumento do risco de queimadas.
- 2

SE: bioma Caatinga + estação primavera + seca alta
ENTÃO: risco de fogo alto
(confiança: 99,5%)

A Caatinga, por ser um bioma naturalmente mais seco, combinada com períodos de estiagem prolongada na primavera, apresenta altíssima probabilidade de ocorrência de incêndios. Isso reforça o papel do tipo de bioma como fator crítico no risco de fogo.



12M+

Registros Processados


Cache Parquet reduz carregamento para segundos

95%


Maior Confiança

Queimadas Registradas 2023

2023 - 2 Clusters



2023 - 7 Clusters



Resultados — Padrões Descobertos

- **Mapa queimadas 2023**


Em 2023, a Amazônia sofreu:

- seca histórica;
- aumento de temperatura;
- efeitos intensificados do El Niño;
- aumento da vulnerabilidade a incêndios florestais.


Isso pode ter feito o Norte apresentar um comportamento muito diferente do restante do país.

Queimadas Registradas 2024

2024 - 2 Clusters



2024 - 7 Clusters



Resultados — Padrões Descobertos

- **Mapa queimadas 2024**


Em 2024, a região amazônica continuou apresentando condições críticas relacionadas aos incêndios florestais, com:

- períodos prolongados de seca;
- temperaturas acima da média;
- baixa umidade em diversas áreas da Amazônia;
- aumento da pressão ambiental causada por queimadas e desmatamento.


Esses fatores podem ter contribuído para que a região Norte mantivesse um comportamento distinto do restante do Brasil nos padrões de risco de incêndio identificados pelo clustering.

Queimadas Registradas 2025

2025 - 2 Clusters



2025 - 7 Clusters



Resultados — Padrões Descobertos

- **Mapa queimadas 2025**

Em 2025, o Nordeste passou a apresentar maior destaque nos padrões de risco de incêndio identificados pelo clustering, possivelmente influenciado por condições climáticas extremas observadas ao longo do ano, como:

- intensificação da seca no Nordeste;
- ondas de calor recorrentes;
- temperaturas acima da média;
- baixa umidade do ar;
- avanço de áreas suscetíveis à desertificação e queimadas.

Relatórios da Agência Nacional de Águas (ANA) apontaram que o Nordeste registrou uma das piores condições de seca dos últimos anos em 2025, enquanto estudos climáticos também relacionaram o aumento das ondas de calor e da estiagem ao crescimento da vulnerabilidade a incêndios florestais no Brasil.

Essa mudança em relação aos anos anteriores sugere que os padrões de risco de incêndio são dinâmicos e fortemente influenciados pelas condições ambientais e meteorológicas específicas de cada período



Conclusão

Principais Descobertas

- Padrões climáticos robustos entre biomas e estados
- TO e PA como regiões críticas com correlações acima de 88%
- Cache Parquet demonstrou ganho expressivo de performance
- K-Means identificou epicentros com alta coerência geográfica

Referências

Referências:

INPE · Base dos Dados · Scikit-learn · Agrawal & Srikant (Apriori, 1994) · MacQueen (K-Means, 1967)
Seca no Brasil (Nordeste, 2024–2025)

AGÊNCIA NACIONAL DE ÁGUAS E SANEAMENTO BÁSICO (ANA).

Monitor de Secas do Brasil – Relatórios e Painéis Interativos.

Disponível em: <https://www.gov.br/ana/pt-br/assuntos/monitor-de-secas>