

Aplicação de K-Means e Regras de Associação na Análise de Queimadas no Brasil

Autores

Thiago Plancke

Mateus Linardi

Kauê Filier Lima

Projeto desenvolvido para a disciplina de Mineração de Dados.

Resumo

Este trabalho apresenta uma análise de focos de queimadas no Brasil utilizando técnicas de mineração de dados e aprendizado de máquina. Foram utilizados dados públicos da plataforma Base dos Dados, extraídos da tabela de microdados de queimadas do Instituto Nacional de Pesquisas Espaciais (INPE), referentes ao período de 2023 a 2025.

Os algoritmos aplicados incluem o K-Means, utilizado para clusterização espacial, e o Apriori, empregado na mineração de regras de associação entre variáveis climáticas, biomas, estações do ano e risco de fogo. Os resultados demonstraram a formação de agrupamentos geográficos de focos de queimadas e identificaram regras relevantes associando baixa precipitação, seca elevada e primavera ao alto risco de fogo.

O estudo contribui para a compreensão de padrões ambientais relacionados às queimadas e demonstra como técnicas de Inteligência Artificial podem apoiar análises de dados climáticos e territoriais.

Palavras-chave: Mineração de Dados; Machine Learning; Clusterização; Regras de Associação; Queimadas; Análise Ambiental.

1. Introdução

As queimadas representam um problema ambiental de grande relevância no Brasil, afetando biomas, municípios, qualidade do ar, biodiversidade e diversas atividades humanas. A recorrência desses eventos está relacionada a fatores climáticos, territoriais e sazonais, como períodos prolongados sem chuva, baixos índices de precipitação, estação do ano e características específicas de cada bioma.

A identificação de padrões em grandes volumes de dados pode auxiliar na compreensão das regiões mais afetadas e das condições mais associadas ao risco de fogo. Estudos de análise ambiental frequentemente utilizam estatísticas descritivas, mapas temáticos, modelos de agrupamento e técnicas de mineração de regras para interpretar fenômenos complexos.

Entretanto, analisar apenas a quantidade de focos por localidade pode limitar a interpretação do problema. Dessa forma, este projeto combina técnicas de clusterização espacial com regras de associação, buscando relacionar a distribuição geográfica das queimadas às variáveis climáticas e ambientais.

O objetivo deste trabalho é aplicar técnicas de mineração de dados para analisar focos de queimadas no Brasil entre 2023 e 2025, identificando agrupamentos espaciais e padrões frequentes associados ao alto risco de fogo.

2. Metodologia

2.1 Base de Dados

Os dados foram obtidos por meio da plataforma Base dos Dados, a partir da tabela `br_inpe_queimadas.microdados`, que disponibiliza registros de focos de queimadas monitorados pelo INPE. A consulta SQL utilizada no projeto seleciona dados dos anos de 2023, 2024 e 2025, enriquecidos com nomes de estados e municípios por meio das tabelas de diretórios brasileiros.

A base local, armazenada em formato Parquet, possui 12.903.132 registros e 14 atributos antes do processamento. Após as etapas de limpeza e normalização, foram mantidos 12.247.168 registros e 17 atributos.

Distribuição dos registros limpos por ano

Ano	Quantidade de Registros
2023	4.326.247
2024	7.850.298
2025	70.623

Variáveis utilizadas no projeto

Variável	Descrição
<code>ano, mes</code>	Período do registro

bioma	Bioma associado ao foco de queimada
sigla_uf, sigla_uf_nome	Estado do registro
id_municipio, id_municipio_nome	Município do registro
latitude, longitude	Localização geográfica
satelite	Satélite responsável pela detecção
dias_sem_chuva	Quantidade de dias sem chuva
precipitacao	Nível de precipitação
risco_fogo	Indicador de risco de fogo
potencia_radiativa_fogo	Potência radiativa do foco de fogo

2.2 Pré-processamento

O pré-processamento foi realizado no arquivo `pipeline.py` e incluiu as seguintes etapas:

1. Leitura do cache local `queimadas_2023_2025.parquet` ou download via BigQuery, caso o arquivo não existisse;
2. Conversão das colunas numéricas para o tipo `float32`;
3. Remoção de valores ausentes, infinitos e registros inconsistentes;
4. Filtragem de coordenadas válidas para o território brasileiro;
5. Remoção de outliers nas variáveis `precipitacao`, `risco_fogo` e `dias_sem_chuva`, utilizando os percentis de 1% e 99%;
6. Normalização Min-Max das variáveis `risco_fogo`, `dias_sem_chuva` e `precipitacao`.

As variáveis normalizadas foram utilizadas no processo de clusterização para reduzir o impacto de diferenças de escala entre os atributos.

2.3 Algoritmos Utilizados

2.3.1 Clusterização com K-Means

O algoritmo K-Means foi utilizado para identificar grupos semelhantes de focos de queimadas. As variáveis utilizadas na clusterização foram:

- latitude
- longitude
- risco_fogo_normalizado
- dias_sem_chuva_normalizado
- precipitacao_normalizado

Para melhorar o desempenho e manter representatividade geográfica, o projeto utiliza uma amostragem por estado, limitada a 500 focos por unidade federativa em cada ano. O número ideal de clusters foi definido por meio da Regra do Cotovelo, avaliando a inércia para diferentes valores de *k*.

Na execução validada do projeto, o melhor valor encontrado foi:


Ano	Melhor valor de k
-----	-------------------

2023	2
------	---


2024	2
------	---

2025	2
------	---


Os resultados da clusterização foram exportados em mapas interativos Folium:



- mapa_kmeans_2023



- mapa_kmeans_2024



- mapa_kmeans_2025

2.3.2 Regras de Associação com Apriori

O algoritmo Apriori foi aplicado para identificar padrões frequentes entre variáveis climáticas, ambientais e sazonais. Para isso, variáveis numéricas foram categorizadas da seguinte forma:

Variável Original	Categorias Criadas
precipitacao	chuva_baixa, chuva_media, chuva_alta
dias_sem_chuva	seca_baixa, seca_media, seca_alta
risco_fogo	risco_baixo, risco_medio, risco_alto
potencia_radiativa_fogo	potencia_baixa, potencia_media, potencia_alta
mes	verao, outono, inverno, primavera

categoria_chuva	categoria_seca	categoria_risco	categoria_potencia	estacao
chuva_baixa	seca_alta	risco_alto	potencia_media	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_baixa	primavera
chuva_baixa	seca_alta	risco_alto	potencia_alta	primavera

As transações foram formadas por itens relacionados à chuva, seca, bioma, potência radiativa, estação do ano e risco de fogo.

Os parâmetros utilizados no Apriori foram:

Parâmetro	Valor
Suporte mínimo	0,015
Confiança mínima	0,70
Lift mínimo	1,30

Amostra máxima 50.000
registros

O projeto filtra regras cujo consequente seja `risco=risco_alto`, priorizando relações diretamente associadas ao elevado risco de fogo.

3. Resultados e Discussão

3.1 Escolha de Parâmetros

Para a clusterização, foram testados diferentes valores de `k` por meio da Regra do Cotovelo. A inércia foi calculada para cada quantidade de clusters, e o projeto selecionou o valor que apresentou maior redução relativa. Para os anos analisados, o valor escolhido foi `k = 2`.

No algoritmo Apriori, os limites de suporte, confiança e lift foram definidos de forma a manter apenas regras com frequência mínima relevante, alta confiabilidade e associação positiva significativa.

3.2 Resultados dos Clusters

Os mapas gerados demonstram a separação dos focos de queimadas em dois grupos principais para cada ano analisado. Como as variáveis utilizadas incluem localização geográfica, risco de fogo, dias sem chuva e precipitação, os clusters representam combinações de proximidade espacial e condições climáticas semelhantes.

Essa divisão permite observar regiões com características semelhantes de queimadas, apoiando a interpretação espacial dos focos ao longo do período

analisado. Os centroides dos clusters também foram adicionados aos mapas, facilitando a visualização do centro aproximado de cada agrupamento.


Análise Complementar com Maior Granularidade Espacial

Além da configuração principal adotada no projeto ($k = 2$), foram realizados testes exploratórios utilizando valores maiores de k , com o objetivo de obter uma segmentação geográfica mais detalhada dos focos de queimadas no território brasileiro.


Em uma análise complementar baseada exclusivamente nas coordenadas geográficas (*latitude* e *longitude*), foi utilizada uma configuração com $k = 7$, permitindo identificar agrupamentos espaciais associados a regiões ambientais específicas do Brasil. Os clusters identificados representam áreas como Amazônia Ocidental, Amazônia Oriental, Arco do Desmatamento, Cerrado Norte/Nordeste, Cerrado Centro-Oeste, Pantanal e regiões do Sul/Sudeste.

Os resultados mostraram que os agrupamentos relacionados à Amazônia e ao Arco do Desmatamento apresentaram maior concentração de focos e maiores valores médios de risco de fogo, enquanto os clusters associados ao Sul e Sudeste apresentaram menor intensidade relativa de ocorrências.


Essa análise complementar demonstra que diferentes valores de k podem fornecer interpretações distintas da distribuição espacial das queimadas. Enquanto valores menores favorecem uma visão mais geral dos padrões climáticos e territoriais, valores maiores permitem identificar regiões ambientais específicas com maior nível de detalhamento geográfico.



- Mapa K-7 (2023)



- Mapa K-7 (2024)





- Mapa K-7 (2025)

3.3 Visualizações

O projeto gera gráficos de barras com a quantidade de focos de queimadas por estado em cada ano. A escala logarítmica foi utilizada para melhorar a leitura dos dados, devido à grande diferença entre estados com alta concentração de registros e estados com menor quantidade de ocorrências.

Além das visualizações estatísticas, os mapas interativos Folium permitem explorar os focos de queimadas por localização, cluster, município, estado e quantidade de dias sem chuva.





3.4 Regras Encontradas

O algoritmo Apriori encontrou 31 regras associadas ao alto risco de fogo. A regra mais forte identificada foi:

Antecedente	Consequente	Supporte	Confiança	Lift
chuva=chuva_baixa + estacao=primavera + seca=seca_alta	risco=risco_alto	0,2039	0,9987	1,3789

Essa regra indica que registros caracterizados por baixa precipitação, seca elevada e ocorrência durante a primavera apresentam probabilidade extremamente alta de associação ao risco elevado de fogo.

Outras regras relevantes também relacionam [seca_alta](#), [primavera](#), [Caatinga](#), [Cerrado](#), [Pantanal](#) e baixa precipitação ao alto risco de queimadas. Esses resultados sugerem que o período seco e a sazonalidade possuem papel fundamental na ocorrência de condições favoráveis ao fogo.

Principais regras exportadas em [regras_apriori.csv](#)

Antecedente	Consequente	Supporte	Confiança	Lift
chuva=chuva_baixa + estacao=primavera + seca=seca_alta	risco=risco_alto	0,2039	0,9987	1,3789

bioma=Caatinga + estacao=primavera + risco=risco_alt	0,0233	0,9957	1,374
seca=seca_alta	o		8
bioma=Caatinga + chuva=chuva_baixa + risco=risco_alt	0,0301	0,9954	1,374
seca=seca_alta	o		3
bioma=Cerrado + estacao=primavera + risco=risco_alt	0,0954	0,9940	1,372
seca=seca_alta	o		3
estacao=primavera + risco=risco_alt	0,0516	0,9912	1,368
potencia=potencia_media + o			5
seca=seca_alta			

4. Conclusão

O trabalho demonstrou que técnicas de aprendizado de máquina e mineração de dados podem auxiliar significativamente na análise de queimadas no Brasil. A clusterização com K-Means permitiu identificar agrupamentos espaciais de focos de queimadas, enquanto o algoritmo Apriori revelou padrões frequentes relacionados ao alto risco de fogo.

Os resultados mostram que baixa precipitação, seca elevada e primavera aparecem fortemente associadas ao risco elevado de queimadas. Biomas como Caatinga, Cerrado, Amazônia e Pantanal também surgiram em regras relevantes, evidenciando a importância dos fatores ambientais e sazonais na interpretação desses eventos.

Como limitação, o projeto utiliza amostragem para melhorar o desempenho computacional dos algoritmos e trabalha com os dados disponíveis no período de 2023 a 2025. Como trabalhos futuros, recomenda-se testar outros algoritmos de

clusterização, incluir métricas como Silhouette Score, comparar modelos supervisionados e expandir a análise para séries temporais mais longas.

Referências

BASE DOS DADOS. *Base dos Dados: repositório público de bases brasileiras*. Disponível em: <https://basedosdados.org/>. Acesso em: 28 maio 2026.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (INPE). *Programa Queimadas*. Disponível em: <https://terrabrasilis.dpi.inpe.br/queimadas/>. Acesso em: 28 maio 2026.

AGRAWAL, Rakesh; SRIKANT, Ramakrishnan. *Fast algorithms for mining association rules*. In: INTERNATIONAL CONFERENCE ON VERY LARGE DATA BASES, 20., 1994. Proceedings. Santiago: VLDB, 1994.

MACQUEEN, J. *Some methods for classification and analysis of multivariate observations*. In: BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1967. Proceedings. Berkeley: University of California Press, 1967.